



RBC — Raciocínio Baseado em Casos

Uma abordagem de **Inteligência Artificial** que resolve problemas novos reutilizando soluções de experiências passadas — imitando a forma como os seres humanos pensam e aprendem.

INTELIGÊNCIA ARTIFICIAL

IA COGNITIVA

Agenda

O que veremos hoje

01

Conceito de RBC

Definição, origem e motivação cognitiva

02

Ciclo das 4 Etapas

Recuperação, Reutilização, Revisão e Retenção

03

Medidas de Similaridade

Euclidiana, Manhattan e Jaccard

04

Aplicações e Comparações

RBC vs. outras abordagens de IA

05

Prática

Base de dados e próxima atividade

Glossário de IA — Parte 1: Termos Fundamentais

Explore a terminologia essencial da Inteligência Artificial com definições claras e concisas.

Inteligência Artificial (IA)

Simulação da inteligência humana por máquinas, programadas para pensar, aprender e resolver problemas como humanos, em diversas áreas do conhecimento.

Machine Learning (Aprendizado de Máquina)

Subcampo da IA que permite que sistemas aprendam a partir de dados, identifiquem padrões e tomem decisões com mínima intervenção humana, sem serem explicitamente programados.

Deep Learning (Aprendizado Profundo)

Um tipo de Machine Learning que utiliza redes neurais artificiais com múltiplas camadas (profundas) para analisar grandes volumes de dados, como imagens, voz e texto, revelando padrões complexos.

Rede Neural Artificial

Modelo computacional inspirado na estrutura do cérebro humano, composto por nós interconectados que processam e transmitem informações, ajustando-se para aprender com os dados.

Algoritmo

Conjunto finito de regras bem definidas e não ambíguas para resolver um problema ou realizar uma tarefa em um número finito de passos, sendo a base para qualquer programa de computador.

Glossário de IA — Parte 2: Dados e Modelos

Aprofunde seu conhecimento nos pilares da Inteligência Artificial: os dados que a alimentam e como os modelos são construídos e avaliados.

Dataset (Conjunto de Dados)

Coleção organizada de dados (textos, imagens, números) usada para treinar e testar modelos de IA, permitindo que aprendam padrões e relações.

Treinamento e Teste

Treinamento: Processo onde o modelo de IA aprende padrões a partir de um subconjunto de dados.

Teste: Avaliação do modelo em dados novos, nunca vistos, para medir sua capacidade de generalização.

Overfitting (Sobreajuste)

Fenômeno onde o modelo se adapta excessivamente aos dados de treinamento, capturando ruídos e detalhes irrelevantes, perdendo a capacidade de prever novos dados com precisão.

Underfitting (Subajuste)

Ocorre quando um modelo é muito simplificado e falha em capturar os padrões essenciais nos dados de treinamento, resultando em um desempenho ruim tanto nos dados treinados quanto nos novos dados.

Feature (Atributo/Característica)

Uma variável individual ou coluna de dados que serve como entrada para o modelo. Por exemplo, a idade ou a renda de um cliente são features.

Label (Rótulo)

A variável de saída ou o valor que o modelo de IA tenta prever. É a "resposta correta" em um conjunto de dados supervisionado, como a classificação de uma imagem ou o preço de uma casa.

Glossário de IA — Parte 3: Tipos de Aprendizado e Técnicas

Explore os diferentes paradigmas de aprendizado de máquina e as técnicas fundamentais para a aplicação da Inteligência Artificial.

Aprendizado Supervisionado

Treina um modelo usando um conjunto de dados rotulados, onde cada entrada tem uma saída conhecida. O objetivo é aprender um mapeamento da entrada para a saída para fazer previsões em novos dados.

Aprendizado Não Supervisionado

Lida com dados não rotulados, procurando por padrões e estruturas intrínsecas nos dados sem orientação prévia. Utilizado para agrupamento, detecção de anomalias e redução de dimensionalidade.

Aprendizado por Reforço

Um agente aprende a tomar decisões através de interações com um ambiente, recebendo recompensas ou punições. O objetivo é maximizar a recompensa acumulada ao longo do tempo, como em jogos ou robótica.

Classificação

Tarefa de prever uma categoria discreta (ou rótulo) para um item de dados. Exemplos incluem identificar se um e-mail é spam ou não-spam, ou categorizar uma imagem como "cachorro" ou "gato".

Regressão

Tarefa de prever um valor contínuo para um item de dados. Exemplos incluem estimar o preço de uma casa com base em suas características ou prever a temperatura para o dia seguinte.

Clustering (Agrupamento)

Técnica de aprendizado não supervisionado que organiza dados em grupos (clusters) onde os itens dentro de um cluster são mais semelhantes entre si do que com itens em outros clusters, sem rótulos predefinidos.



O que é Raciocínio Baseado em Casos?

RBC é uma técnica de Inteligência Artificial que resolve problemas novos **reutilizando soluções de problemas semelhantes já resolvidos**. Em vez de seguir regras pré-definidas, o sistema consulta um histórico de casos passados — imitando o raciocínio humano baseado em experiência.

- 📄 Exemplo clássico: um médico diagnostica um paciente com base em casos semelhantes já vistos ao longo de sua carreira.

A Inspiração Cognitiva do RBC

Como os humanos raciocinam

Pessoas tomam decisões baseadas em experiências anteriores. Ao enfrentar um problema novo, buscamos na memória situações parecidas e adaptamos o que funcionou antes.

Como o RBC imita isso

O RBC formaliza esse processo: armazena casos passados em uma **base de conhecimento** e usa mecanismos de similaridade para recuperar e adaptar soluções relevantes automaticamente.

Essa abordagem torna o sistema mais **flexível e adaptável** do que sistemas baseados em regras rígidas.

Estrutura de um Caso no RBC

Cada **caso** armazenado na base de conhecimento é composto por dois elementos fundamentais:


Problema (Situação)

Descrição do contexto, atributos e características do problema enfrentado. É a "pergunta" do caso.

Solução (Resposta)

A ação ou decisão tomada para resolver o problema, incluindo o resultado obtido. É a "resposta" do caso.


Opcionalmente, um caso pode incluir também o **resultado** (sucesso ou falha da solução) e **lições aprendidas**, enriquecendo a base de conhecimento.



O Ciclo do RBC: 4 Etapas

O RBC opera em um ciclo contínuo de quatro etapas, conhecido como o **Ciclo dos 4 Rs**. Cada novo problema percorre esse fluxo, enriquecendo a base de conhecimento ao final.

Visão Geral do Ciclo RBC



Esse ciclo garante que o sistema aprenda continuamente, tornando-se mais preciso a cada novo caso processado.



Etapa 1 — Recuperação de Casos

O sistema busca na base de conhecimento os casos passados **mais semelhantes** ao problema atual. A qualidade da recuperação depende diretamente do mecanismo de similaridade utilizado.

Como Funciona a Recuperação

Medidas de Distância

Para variáveis numéricas, utiliza-se distância Euclidiana ou de Manhattan para calcular o quão próximos dois casos são no espaço de atributos.

Índices de Similaridade

Para texto ou imagens, índices como Jaccard ou similaridade de cosseno medem a sobreposição entre os atributos dos casos.

Exemplo Prático

Um sistema de suporte técnico recupera soluções de problemas semelhantes de um banco de dados de chamados anteriores, agilizando o atendimento.



Etapa 2 — Reutilização da Solução

Após recuperar um caso similar, o sistema tenta **aplicar a solução existente** ao novo problema. Dependendo do grau de similaridade, a solução pode ser usada diretamente ou precisar de adaptações.

Caso Idêntico

Solução reutilizada sem alterações — aplicação direta e imediata.

Caso Semelhante

Solução ajustada para se adequar às particularidades do novo problema.



Etapa 3 — Revisão da Solução

O que acontece nesta etapa?

A solução sugerida é **testada no novo problema**. Se necessário, ajustes são feitos antes de aplicá-la definitivamente. Em alguns sistemas, especialistas humanos avaliam e corrigem a solução proposta.

Exemplo

Um sistema de manutenção preditiva sugere a troca de uma peça com base em falhas anteriores, mas um técnico especialista pode revisar e validar a recomendação antes da execução.

Etapa 4 — Retenção de Novos Casos

Se a solução foi bem-sucedida, o novo caso é **armazenado na base de conhecimento** para referência futura. Esse processo garante aprendizagem incremental: quanto mais casos armazenados, melhor o sistema se torna ao longo do tempo.



Aprendizagem Incremental

O sistema cresce e melhora continuamente com cada novo caso resolvido.



Exemplo: Chatbot

Um chatbot de suporte técnico aprende novas soluções com base nas interações com usuários, expandindo seu repertório.

Quando Reter ou Descartar um Caso?

Nem todo caso novo precisa ser armazenado. A decisão de retenção envolve critérios de qualidade e relevância:



Reter

Quando a solução foi bem-sucedida e o caso traz informação nova não coberta por casos existentes.



Descartar

Quando o caso é redundante (já coberto por outros) ou quando a solução falhou e não gerou aprendizado útil.



Generalizar

Casos similares podem ser fundidos em um caso mais geral, evitando redundância e mantendo a base enxuta.

Medidas de Similaridade


Para que o RBC funcione bem, é essencial medir com precisão o quão parecidos dois casos são.
Diferentes tipos de dados exigem diferentes métricas.

$$E = mc^2$$



$$a^2 + b^2 = c^2$$

$$\int f(x) dx$$



$$F = ma$$

$$\sin^2 \theta + \cos^2 \theta = 1$$

$$\lim_{x \rightarrow \infty} \frac{1}{x} = 0$$

$$e^{i\pi} + 1 = 0$$

$$\pi \approx 3.14159\dots$$

Distância Euclidiana

Mede a distância entre dois pontos em um espaço n-dimensional. **Quanto menor a distância, mais similares os casos.** Ideal para dados numéricos contínuos.

Fórmula Geral

$$d(A, B) = \sqrt{\sum_{i=1}^n (A_i - B_i)^2}$$

Exemplo com Sintomas

Caso 1: (Febre=1, Tosse=1, Dor de cabeça=0)

Caso 2: (Febre=1, Tosse=0, Dor de cabeça=1)

$$d = \sqrt{(1-1)^2 + (1-0)^2 + (0-1)^2} = \sqrt{2} \approx 1,41$$

Interpretação

Os dois casos têm distância $\sqrt{2} \approx 1,41$, indicando similaridade moderada. Casos com distância zero seriam idênticos.

Aplicações: comparação de sintomas médicos, perfis de clientes, características de produtos.

Distância de Manhattan

Soma das **diferenças absolutas** entre as coordenadas. Útil quando as dimensões representam características independentes, especialmente para dados categóricos ou numéricos discretos.

Fórmula

$$d(A, B) = \sum_{i=1}^n |A_i - B_i|$$

Exemplo: Receitas de Bolo

Receita A: (Farinha=2, Açúcar=1, Ovos=3)

Receita B: (Farinha=3, Açúcar=2, Ovos=3)

$$d = |2 - 3| + |1 - 2| + |3 - 3| = 1 + 1 + 0 = 2$$

Euclidiana vs. Manhattan

Euclidiana: mede a linha reta entre dois pontos — sensível a grandes diferenças em uma única dimensão.

Manhattan: mede o caminho percorrido em grade — mais robusta quando há muitas dimensões independentes.

Distância de Jaccard

Mede a **interseção entre conjuntos de palavras** de dois textos. Muito utilizada em análise de consultas em mecanismos de busca e comparação de documentos.

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Texto 1

"Dor no peito e dificuldade para respirar"

A = {dor, peito, dificuldade, respirar}

Texto 2

"Dificuldade respiratória e dor torácica"

B = {dificuldade, respiratória, dor, torácica}

Resultado

Interseção: {dor, dificuldade} = 2 palavras

União: 6 palavras

J = 2/6 = 0,33 → Baixa Similaridade

Similaridade de Cosseno

Outra medida importante, muito usada em **processamento de linguagem natural**. Mede o ângulo entre dois vetores de atributos — quanto menor o ângulo, maior a similaridade.

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \cdot \|B\|}$$

Quando usar?

Ideal para comparar documentos de texto representados como vetores de frequência de palavras (TF-IDF). Ignora o tamanho dos documentos, focando apenas na direção dos vetores.

Interpretação

Valor próximo de **1**: documentos muito similares.

Valor próximo de **0**: documentos sem relação.

Valor **-1**: documentos opostos (raro em textos).

Comparando as Métricas de Similaridade

Métrica	Tipo de Dado	Sensibilidade	Aplicação Típica
Euclidiana	Numérico contínuo	Alta a outliers	Sintomas, sensores
Manhattan	Numérico/Categórico	Moderada	Perfis, ingredientes
Jaccard	Conjuntos/Texto	Baixa a tamanho	Busca, documentos
Cosseno	Vetores/Texto	Ignora magnitude	NLP, recomendação



RBC vs. Outras Abordagens de IA

O RBC não é a única abordagem de IA disponível. Compreender suas diferenças em relação a **Sistemas Baseados em Regras** e **Aprendizado de Máquina** ajuda a escolher a ferramenta certa para cada problema.

Comparação entre Abordagens

RBC	Sistemas Baseados em Regras	Aprendizado de Máquina
Baseado em experiência e casos específicos	Requer conjunto de regras fixas e explícitas	Necessita grande volume de dados para treinar
Adaptável a novas situações com poucos dados	Difícil de modificar e manter	Modelos preditivos de alta performance
Explicável: mostra o caso de referência	Totalmente explicável e auditável	Frequentemente "caixa-preta"
Ideal para domínios com poucos dados	Ideal para domínios bem definidos	Ideal para grandes volumes de dados

Vantagens do RBC



Rápida Implementação

Não exige modelagem complexa — basta ter casos históricos relevantes.



Explicabilidade

As decisões são justificadas por casos reais, facilitando auditoria e confiança.



Aprendizado Contínuo

A base cresce com o uso, melhorando progressivamente sem retreinamento.



Poucos Dados

Funciona bem mesmo com bases de dados pequenas, ao contrário do ML tradicional.

Limitações do RBC

Escalabilidade

À medida que a base cresce, a busca por casos similares pode se tornar computacionalmente custosa sem indexação adequada.

Qualidade da Base

O sistema é tão bom quanto os casos armazenados. Casos incorretos ou incompletos degradam a qualidade das soluções.

Definição de Similaridade

Escolher a métrica e os pesos corretos para os atributos é um desafio que exige conhecimento do domínio.


Problemas Inéditos

Se nenhum caso similar existir na base, o sistema pode falhar ou propor soluções inadequadas.


Aplicações do RBC — Medicina

O diagnóstico médico é uma das aplicações mais clássicas do RBC. Sistemas como o **MYCIN** e seus sucessores utilizam casos de pacientes anteriores para sugerir diagnósticos e tratamentos, auxiliando médicos na tomada de decisão clínica.

- Recuperação de casos com sintomas similares ao paciente atual
- Sugestão de diagnóstico e protocolo de tratamento
- Revisão por especialista e armazenamento do novo caso



Aplicações do RBC — Suporte Técnico e Jurídico



Suporte Técnico

Sistemas de help desk recuperam soluções de chamados anteriores similares, reduzindo o tempo de resolução e padronizando o atendimento.



Direito

Sistemas jurídicos recuperam jurisprudências e precedentes legais similares para auxiliar advogados na construção de argumentos e estratégias.



Manutenção Preditiva

Sistemas industriais identificam padrões de falha com base em histórico de equipamentos, sugerindo manutenções preventivas antes da quebra.

Aplicações do RBC — Recomendação e E-commerce

Sistemas de recomendação utilizam RBC para sugerir produtos, filmes ou músicas com base no histórico de preferências de usuários similares. A lógica é simples: **"usuários com gostos parecidos tendem a gostar das mesmas coisas."**

Netflix / Spotify

Recomendação de conteúdo baseada em perfis de usuários similares.

E-commerce

"Clientes que compraram X também compraram Y" — RBC em ação.

Turismo

Sugestão de destinos e pacotes com base em viagens anteriores de perfis similares.



RBC em Sistemas Híbridos

Na prática moderna, o RBC raramente opera de forma isolada. Ele é frequentemente combinado com outras técnicas de IA para criar **sistemas híbridos mais robustos**:

1

RBC + Regras

Regras filtram casos candidatos; RBC refina a solução final.

2

RBC + ML


ML classifica o problema; RBC busca o caso mais similar na classe identificada.

3

RBC + NLP

Processamento de linguagem natural extrai atributos de textos para alimentar o RBC.

Exemplo Completo: Sistema de Diagnóstico Médico



Este fluxo ilustra como o ciclo completo do RBC se aplica em um contexto real de diagnóstico médico, desde a entrada dos sintomas até o enriquecimento da base de conhecimento.

Exemplo Completo: Suporte Técnico com RBC

Problema Novo

Usuário relata: "Meu computador não liga após atualização do sistema operacional."

Recuperação

Sistema encontra 3 casos similares com 85%, 78% e 72% de similaridade.

Reutilização

Solução do caso mais similar: reiniciar em modo de recuperação e restaurar ponto anterior.

Revisão e Retenção

Técnico aplica a solução, confirma o sucesso e o novo caso é armazenado com os detalhes específicos do hardware do usuário.

Representação de Casos: Atributos e Pesos

A eficácia do RBC depende de como os casos são **representados**. Cada atributo pode ter um peso diferente na medida de similaridade:

1

Seleção de Atributos

Identificar quais características do problema são relevantes para a comparação entre casos.

2

Atribuição de Pesos

Atributos mais importantes recebem pesos maiores na fórmula de similaridade ponderada.

3

Normalização

Atributos com escalas diferentes devem ser normalizados para evitar que dominem o cálculo de distância.

$$sim(A, B) = \frac{\sum_{i=1}^n w_i \cdot sim_i(A_i, B_i)}{\sum_{i=1}^n w_i}$$

Similaridade Ponderada na Prática

Considere um sistema de diagnóstico onde **febre** tem peso 3, **tosse** tem peso 2 e **dor de cabeça** tem peso 1:

Atributo	Peso	Caso A	Caso B	sim_i
Febre	3	1	1	1,0
Tosse	2	1	0	0,0
Dor de cabeça	1	0	1	0,0

Similaridade ponderada: $(3 \times 1 + 2 \times 0 + 1 \times 0) / (3 + 2 + 1) = 3/6 = 0,50$ — similaridade moderada de 50%.

Indexação e Eficiência na Recuperação

Com bases de dados grandes, buscar o caso mais similar pode ser lento. Técnicas de **indexação** aceleram a recuperação:



Árvores KD

Estrutura de dados que particiona o espaço de atributos, reduzindo o número de comparações necessárias.



Clustering

Agrupa casos similares em clusters; a busca é feita apenas no cluster mais relevante.



Hashing

Mapeia casos para buckets por similaridade, permitindo recuperação quase instantânea.

Avaliação de Sistemas RBC

Como medir se um sistema RBC está funcionando bem? As principais métricas de avaliação incluem:

k

Vizinhos Mais Próximos

Número de casos recuperados para análise
(parâmetro k no algoritmo kNN).

$P@k$


Precisão

Proporção de casos recuperados que são realmente
relevantes para o problema.

F_1

F1-Score

Média harmônica entre precisão e recall — equilíbrio
entre os dois.



RBC e Explicabilidade da IA

Uma das grandes vantagens do RBC no contexto atual é sua **explicabilidade natural**. Ao contrário de redes neurais profundas, o RBC pode sempre justificar sua decisão mostrando o caso de referência utilizado — um requisito crescente em IA ética e regulamentada.

- ❏ O conceito de **XAI (Explainable AI)** coloca o RBC como uma abordagem naturalmente alinhada com as demandas de transparência e auditabilidade em sistemas de IA modernos.

Tendências Modernas: RBC + IA Generativa

O Novo Cenário

Com a ascensão de LLMs (Large Language Models) como GPT, o RBC está sendo revisitado. Modelos de linguagem podem ser usados para **adaptar soluções de casos** de forma mais sofisticada e natural.

Aplicações Emergentes

- RAG (Retrieval-Augmented Generation): recupera casos relevantes e usa LLM para gerar respostas
- Chatbots médicos e jurídicos com base em casos reais
- Sistemas de design assistido por IA com histórico de projetos

Implementação Prática de RBC em Python

A biblioteca `scikit-learn` oferece o algoritmo **k-Nearest Neighbors (kNN)**, que implementa a lógica central do RBC:

```
from sklearn.neighbors import KNeighborsClassifier
import numpy as np

# Base de casos: [Febre, Tosse, Dor de cabeça]
casos = np.array([[1,1,0],[1,0,1],[0,1,1],[1,1,1]])
diagnosticos = ['Gripe','Sinusite','Resfriado','Gripe']

# Treinar o modelo (base de casos)
knn = KNeighborsClassifier(n_neighbors=2, metric='euclidean')
knn.fit(casos, diagnosticos)

# Novo paciente
novo_caso = np.array([[1,1,0]])
print(knn.predict(novo_caso)) # Output: ['Gripe']
```

Este exemplo simples ilustra como o RBC pode ser implementado usando ferramentas amplamente disponíveis em Python.

Base de Dados para Prática — Kaggle

Para a próxima atividade prática, utilizaremos bases de dados disponíveis no **Kaggle**, uma das maiores plataformas de ciência de dados do mundo.

Acesso

<https://www.kaggle.com/> — cadastro gratuito necessário.

Datasets Sugeridos

Busque por "medical diagnosis", "customer support tickets" ou "symptom checker" para encontrar bases adequadas ao RBC.

Formato

Prefira datasets em CSV com atributos numéricos ou categóricos bem definidos para facilitar o cálculo de similaridade.



Resumo: O Ciclo Completo do RBC

1-Recuperação

(search similar cases in knowledge base using similarity metrics)

2-Reutilização


(adapt retrieved solution to new problem, identical or similar case)

3-Revisão

(test and adjust solution, human expert validation)

4-Retenção

(store successful case in knowledge base for future reference, incremental learning)





Conclusões e Próximos Passos



RBC é poderoso e explicável

Resolve problemas com poucos dados e justifica decisões com casos reais — ideal para domínios críticos como medicina e direito.



A escolha da métrica importa

Euclidiana, Manhattan ou Jaccard — cada tipo de dado exige a medida de similaridade adequada.



Próxima atividade

Implementar um sistema RBC simples usando Python e uma base de dados do Kaggle, aplicando o ciclo completo dos 4 Rs.



Dúvidas? Explore o Kaggle, experimente o código Python apresentado e traga suas descobertas para a próxima aula!